

Relazione di Progetto: Semantic Web Ottimizzazione Ontologica e Inferenza sul Knowledge Graph GQA

Santi Lisi
Matricola: 1000099260

Indice


1	Introduzione: Il Dataset GQA	2
2	Analisi del Dataset Completo e Criticità Strutturali	3
3	Pipeline di Creazione del Subsample Ottimizzato	3
4	Progettazione e Ingegnerizzazione dell'Ontologia (OWL 2)	4
4.1	Tassonomia Profonda (Top-Down su 3 Livelli)	4
4.2	Assiomi di Disgiunzione (Disjointness)	5
4.3	Restrizioni Logiche: Domain e Range con Pattern UnionOf . .	5
4.4	Tratti Matematici e Proprietà Fisiche	6
4.5	Catene Inferenziali Avanzate (Property Chains)	6
5	Collaudo Inferenziale con SPARQL su Virtuoso	7
5.1	Query 1: Gerarchia Spaziale e Transitività	7
5.2	Query 2: Deduzione Simmetrica e Inversa	7
5.3	Query 3: Dimostrazione delle Catene di Proprietà	8
5.4	Query 4: Validazione del Domain tramite UnionOf	8
5.5	Query 5: Esplorazione Statistica del TBox	9
6	Conclusioni e Sviluppi Futuri	10

1 Introduzione: Il Dataset GQA

Il progetto si pone l'obiettivo di modellare, ottimizzare e interrogare il Knowledge Graph estratto dal dataset GQA (Visual Question Answering). Creato originariamente dai ricercatori della Stanford University, il dataset GQA fornisce una ricca rappresentazione basata su grafi delle relazioni spaziali, fisiche e semantiche tra oggetti all'interno di migliaia di immagini reali.

A livello teorico, ogni immagine nel dataset può essere vista come un grafo semantico in cui:

- Ogni nodo rappresenta un oggetto visibile (es. *person*, *apple*, *table*, *car*).
- Ogni arco direzionale rappresenta una relazione (Object Property) che intercorre tra due entità (es. *eating*, *sitting-on*, *above*, *near*).



Grafo semantico reale estratto (ID: 101).

Scena (ID: 101) dal dataset GQA.

Figura 1: Esempio di immagine tradotta in grafo semantico.

Lo scopo principale di questa conversione in formato RDF (Resource Description Framework) è quello di rendere la conoscenza "machine-readable", permettendo di utilizzare l'ontologia come base strutturale per architetture di Deep Learning, come le Graph Convolutional Networks (GCN), le quali richiedono input densi, logicamente coerenti e privi di ambiguità per poter generalizzare efficacemente.

2 Analisi del Dataset Completo e Criticità Strutturali

La prima fase del progetto ha visto la conversione "brute-force" dell'intero dataset GQA in formato .ttl (Turtle). Il volume di dati originale era imponente: oltre 85.000 immagini, circa 1.700 classi distinte (concetti nominali) e circa 300 predicati (proprietà).

Tuttavia, un'analisi esplorativa condotta sui dati grezzi convertiti ha rivelato forti limitazioni intrinseche che rendevano il dataset intero inadatto sia all'inferenza logica che al Machine Learning:

- Distribuzione a Coda Lunga (Long Tail Distribution): Il dataset soffriva di un gravissimo sbilanciamento statistico. Classi generiche o relative agli sfondi (come *man*, *window*, *sky*, *wall*) contavano oltre un milione di occorrenze, dominando completamente la topologia dei grafi. Di contro, centinaia di classi specifiche (come *blimp*, *walrus*, *stethoscope*) possedevano appena una manciata di istanze.
- Inquinamento delle Feature Spaziali: L'onnipresenza di classi come *sky* o *floor* creava "hub" giganteschi nei grafi (tutti gli oggetti risultavano *under sky* e *above floor*), appiattendolo l'informazione strutturale e rendendo impossibile ai modelli di rete neurale distinguere i pattern di interesse.
- Esplosione Computazionale: La dimensione della matrice di adiacenza generata e il numero spropositato di triple causava rallentamenti critici nei Triple Store semantici, precludendo l'esecuzione fluida delle regole di inferenza (RDFS/OWL).

3 Pipeline di Creazione del Subsample Ottimizzato

A fronte delle limitazioni emerse, si è optato per un approccio qualitativo: invece di utilizzare un dataset sterminato ma rumoroso, è stato implementato un algoritmo in Python per estrarre un Subsample curato e bilanciato. L'obiettivo era ottenere un microcosmo ontologico coerente e computazionalmente trattabile.

Le logiche di estrazione applicate alla pipeline sono state rigorose e multi-step:

1. Selezione di 300 Classi Base: Sono state rimosse tutte le classi ad altissima frequenza (> 10.000 occorrenze) che avrebbero monopolizzato l'attenzione del sistema. Successivamente, sono state scartate le classi con frequenza quasi nulla, isolando esattamente i 300 concetti visivi più rappresentativi ed equilibrati.
2. Selezione di 65 Proprietà Rilevanti: Rispetto alle centinaia di predicati grezzi (spesso contenenti errori di battitura o doppioni), si è applicata una scrematura semantica, preservando le 65 Object Properties maggiormente connesse e semanticamente robuste (azioni fisiche, posizioni spaziali e relazioni di contenimento).
3. Estrazione delle Immagini ("Closed World"): Infine, l'algoritmo ha scandagliato il dataset originale selezionando esattamente 16.000 immagini (14.000 per il Training e 2.000 per il Validation Set) i cui Scene Graph includessero *esclusivamente* le 300 classi e le 65 proprietà precedentemente approvate. Qualsiasi immagine contenente archi o nodi "out-of-vocabulary" è stata scartata, garantendo la purezza ontologica assoluta del subsample.

4 Progettazione e Ingegnerizzazione dell'Ontologia (OWL 2)

Avere un dataset ridotto non è sufficiente. Il file originale RDFS risultava totalmente "piatto", privo di gerarchie e di regole logiche, in cui tutte le classi derivavano direttamente dalla radice e le relazioni non possedevano alcun vincolo matematico.

La fase centrale del lavoro ha visto la stesura programmatica di un TBox rigoroso in formato OWL 2, progettato non solo per validare i dati (ABox), ma per generare attivamente nuova conoscenza grazie al Ragionatore (Reasoner).

4.1 Tassonomia Profonda (Top-Down su 3 Livelli)

Per supportare algoritmi di classificazione, le 300 classi (livello "foglia") sono state agganciate a un albero gerarchico creato *ad hoc* sfruttando il costrutto `rdfs:subClassOf`.

- Livello 1 (Radici Mutuamente Esclusive): Sono state fondate quattro mega-categorie ontologiche assolute: LivingBeing (Esseri viventi), Ina-

nimateObject (Oggetti fisici inanimati), Location (Spazi e strutture) e Substance (Sostanze deperibili o amorfe).

- Livello 2 (Domini Specifici): Sotto LivingBeing nascono i rami Person, Animals, Nature e BodyPart.
Sotto InanimateObject nascono Vehicles, Furniture, Clothing, Sports-Equipment e Item.
Sotto Location si definiscono le distinzioni tra IndoorSpace, Outdoor-Space, FacilityElement e ArchitecturalStructure.
Sotto substance invece abbiamo Food e Beverages.
- Livello 3 (Istanze Base): Le 300 classi del subsample sono state finalmente agganciate al loro dominio pertinente. Ad esempio, le classi *dog*, *cat*, *horse* derivano da Animals, mentre *car*, *bus*, *train* derivano da Vehicles.

4.2 Assiomi di Disgiunzione (Disjointness)

Il paradigma semantico opera sotto la Open World Assumption (OWA): se una regola non vieta espressamente qualcosa, il sistema assume che sia possibile. Per tutelare le reti neurali dall'addestrarsi su inferenze impossibili, sono stati generati blocchi owl:AllDisjointClasses. È stato imposto, ad esempio, che LivingBeing e InanimateObject siano domini disgiunti: un nodo non potrà mai istanziare simultaneamente *Person* e *Vehicles*. Qualora ciò accadesse a causa di rumore nei dati, il database semantico solleverebbe immediatamente un'eccezione logica.

4.3 Restrizioni Logiche: Domain e Range con Pattern UnionOf

Ogni singola proprietà delle 65 ammesse è stata modellata definendone il Dominio (rdfs:domain, chi compie l'azione) e il Codominio (rdfs:range, chi subisce l'azione). Una problematica diffusa risiedeva nelle azioni condivise. L'azione eating, ad esempio, può essere compiuta sia da una *Person* che da un *Animals*. Assegnare un doppio dominio in OWL equivale a un'operazione di intersezione logica (impossibile, data la disgiunzione precedente). La soluzione architetturale è stata l'implementazione dell'operatore owl:unionOf, che crea una super-classe "anonima" corrispondente all'unione insiemistica dei due domini ammessi:

```
ont:eating rdfs:domain [  
    rdf:type owl:Class ;  
    owl:unionOf ( ont:Animals ont:Person )  
] .
```

4.4 Tratti Matematici e Proprietà Fisiche

Al fine di iniettare le regole base della fisica all'interno dell'ontologia, le 65 Object Properties sono state etichettate usando i costrutti avanzati di OWL, consentendo al motore logico di chiudere i triangoli del grafo mancanti nel dataset:

- Proprietà Transitive (owl:TransitiveProperty): Applicata al contenimento spaziale (in). Regola: se A in B , e B in C , allora A in C .
- Proprietà Simmetriche (owl:SymmetricProperty): Utilizzata per concetti di prossimità come near e touching. Regola: se l'automobile è vicina all'albero, inevitabilmente l'albero è vicino all'automobile.
- Inversi Logici (owl:inverseOf): Imprescindibile per la direzionalità tridimensionale. Cablando le coppie antagoniste (es. above opposto a below), il sistema deduce un arco inverso per ogni arco spaziale inserito.
- Asimmetria e Irriflessività: Sono state bloccate proprietà come holding o eating tramite assiomi owl:IrreflexiveProperty. Una persona non può stringere o mangiare se stessa, eliminando così i self-loops spuri dal dataset.

4.5 Catene Inferenziali Avanzate (Property Chains)

Un aspetto fondamentale del progetto è l'utilizzo di owl:propertyChainAxiom. Questo strumento OWL 2 permette di far convergere percorsi formati da più archi verso la deduzione di un arco del tutto nuovo. Esempi sviluppati per il dataset GQA:

1. Contenimento Indiretto: $\text{sitting_on} \circ \text{in} \rightarrow \text{in}$. Una persona che siede su un divano posto in una stanza, viene inferita come trovantesi "in" quella stanza.

2. Ereditarietà della Prossimità: $\text{in} \circ \text{near} \rightarrow \text{near}$. Se una moneta si trova in un cassetto, ed esso è vicino al letto, la moneta erediterà l'arco "vicino" al letto.
3. Azione Visiva Composta: $\text{riding} \circ \text{in_front_of} \rightarrow \text{looking_at}$. Il ragionatore apprende che qualora una persona cavalchi un mezzo, e vi sia un ostacolo di fronte ad esso, la persona deduttivamente starà osservando l'ostacolo.

5 Collaudo Inferenziale con SPARQL su Virtuoso

L'intera ontologia e le 16.000 immagini sono state caricate all'interno di OpenLink Virtuoso. Attraverso l'attivazione della *Rule Set* di inferenza OWL, è stato possibile testare il grafo interrogandolo tramite query SPARQL.

I test seguenti dimostrano inoppugnabilmente che il database è in grado di estrarre fatti logici mai documentati nel file TTL di partenza.

5.1 Query 1: Gerarchia Spaziale e Transitività

Questa query interroga le proprietà above. Grazie al TBox, essa scenderà anche lungo la catena delle sub-property (come on_top_of) ed elaborerà la transitività per mostrare tutto ciò che risiede spazialmente sotto l'oggetto dato.

```
DEFINE input:inference "advanced_rules"
PREFIX ont: <http://progetto-dl-sw.org/ontology#>
PREFIX obj: <http://progetto-dl-sw.org/objects/>

SELECT ?o
FROM <http://progetto-dl-sw.org/advanced>
WHERE {
    obj:1051910 ont:above ?o .
}
```

5.2 Query 2: Deduzione Simmetrica e Inversa

Esplorando le posizioni, chiediamo a Virtuoso di indicarci chi si trova "sotto" un oggetto target. Sebbene nel file sorgente fossero scritti solo archi di tipo

”sopra”, il motore li ribalta dinamicamente usando owl:inverseOf.

```
DEFINE input:inference "advanced_rules"
PREFIX ont: <http://progetto-dl-sw.org/ontology#>
PREFIX obj: <http://progetto-dl-sw.org/objects/>

SELECT ?s
FROM <http://progetto-dl-sw.org/advanced>
WHERE {
    ?s ont:below obj:1051910 .
}
```

5.3 Query 3: Dimostrazione delle Catene di Proprietà

Testiamo la regola riding o in_front_of → looking_at. Il sistema cercherà archi ”looking_at” in modo nativo, calcolando i percorsi composti all’istante e rivelando le direzioni di sguardo dei piloti verso gli ostacoli.

```
DEFINE input:inference "advanced_rules"
PREFIX ont: <http://progetto-dl-sw.org/ontology#>

SELECT ?subj ?obj
FROM <http://progetto-dl-sw.org/advanced>
WHERE {
    ?subj ont:looking_at ?obj .
}
LIMIT 10
```

5.4 Query 4: Validazione del Domain tramite UnionOf

Nel momento in cui un utente estrae l’azione del mangiare, il database deduce automaticamente che il soggetto debba far parte della classe anonima che fonde Persone e Animali.


```

DEFINE input:inference "advanced_rules"
PREFIX ont: <http://progetto-dl-sw.org/ontology#>
PREFIX rdf: <http://www.w3.org/1999/02/22-rdf-syntax-ns
#>

SELECT ?s ?class
FROM <http://progetto-dl-sw.org/advanced>
WHERE {
    ?s ont:eating ?o .
    ?s rdf:type ?class .
}

```

5.5 Query 5: Esplorazione Statistica del TBox

Per validare l'esatto caricamento del subsample elaborato, eseguiamo conteggi diretti sul dizionario ontologico tramite aggregatori SPARQL.

Conteggio esatto delle Classi (Filtro sulle IRI per ignorare le UnionOf):

```

PREFIX owl: <http://www.w3.org/2002/07/owl#>

SELECT (COUNT(DISTINCT ?c) AS ?numero_classi)
FROM <http://progetto-dl-sw.org/advanced>
WHERE {
    ?c a owl:Class .
    FILTER(isIRI(?c))
}

```

Distribuzione dei Tratti Logici sulle 65 Object Properties:

```

PREFIX owl: <http://www.w3.org/2002/07/owl#>

SELECT
  (COUNT(DISTINCT ?p) AS ?totali)
  (COUNT(DISTINCT IF(EXISTS{?p a owl:TransitiveProperty
    }, ?p, ?unb)) AS ?transitive)
  (COUNT(DISTINCT IF(EXISTS{?p a owl:SymmetricProperty},
    ?p, ?unb)) AS ?simmetriche)
FROM <http://progetto-dl-sw.org/advanced>
WHERE {
  ?p a owl:ObjectProperty .
}

```

6 Conclusioni e Sviluppi Futuri

Il monumentale processo di subsampling qualitativo e la successiva modellazione semantica hanno trasformato un dataset visivo piatto e sbilanciato in un Knowledge Graph profondo e denso.

Le regole logiche iniettate tramite OWL 2 (Transitivity, Symmetry, Property Chains e Disjointness) permettono al grafo di materializzare autonomamente le relazioni spaziali latenti, chiudendo poligoni strutturali essenziali per comprendere l'ambiente 3D. Questa architettura rigorosa abbatte drasticamente il rumore e la confusione informativa del dataset GQA originale. Si pone pertanto come base aurea (Gold Standard) per lo sviluppo di reti neurali GCN avanzate, che grazie a questo TBox potranno concentrarsi sui veri pattern relazionali senza essere appesantite dalla codifica ridondante di semplici deduzioni geometriche o fisiche.