

Graph-based Metric Learning for Scene Understanding with Semantic Web Technologies

Track 26 — Graph-based Metric Learning for Scene Understanding with Semantic Web Technologies

Studenti

Santi Lisi
Dario Lazzara
Francesco Granata

Repository GitHub & Docente

Docente: Prof. Antonino Furnari
GitHub: [saintslisi/deeplearning2](https://github.com/saintslisi/deeplearning2)

Il Problema: Oltre i Pixel per il Retrieval Semantico

Perché le feature visive globali falliscono nella composizionalità

Limite del CBIR Classico (Pixel & Texture)

I modelli che lavorano sui soli pixel eccellono nell'apparenza globale, ma soffrono la **composizionalità semantica**:

- ▶ Ignorano i ruoli sintattici e le relazioni d'azione.
- ▶ Non distinguono *“uomo cavalca cavallo”* da *“uomo accarezza cavallo”*.
- ▶ Catturano co-occorrenze e sfondi ma non la struttura.

La Nostra Soluzione Proposta

Mappare le immagini in uno **spazio metrico invariante** combinando:

1. **Scene Graph (GQA)**: Rappresentazione strutturata a grafo (oggetti come nodi, relazioni come archi).
2. **Semantic Web (OWL + Virtuoso)**: Regularizzazione ontologica dei nodi tramite macro-categorie.
3. **Graph Neural Networks (GINE)**: Convoluzioni edge-aware addestrate con **Triplet Margin Loss**.

Domanda di Ricerca: *È possibile superare le baseline puramente visive mappando la topologia dei grafi di scena in embedding densi per il visual retrieval scalabile?*

Dal Visual Genome al Dataset GQA

Partizionamento deterministico e scaling su due ordini di grandezza

Struttura dei Dati

- ▶ Ogni scena è rappresentata come **grafo attribuito**:
 - ▶ **Nodi (V)**: Oggetti annotati con classe e attributi visivi.
 - ▶ **Archi (E)**: Relazioni semantiche e d'azione.
- ▶ ~ 6% del dataset è composto da grafi privi di archi, gestiti come *bag of objects*.

Due Scale Dimensionali Sperimentali

- ▶ **Subset Controllato (~15.410 grafi)**: 771 queries di test, galleria da ~3.500 scene.
- ▶ **Full-Set Scalato (>55.000 grafi)**: 1.000 queries fisse, galleria da oltre 20.000 distrattori.

Partizionamento Deterministico (Seed 42)

Split	Quota	Finalità
Train Set	65%	Addestramento contrastivo
Validation Set	10%	Calibrazione e checkpointing
Gallery (Test)	~23%	Search space (> 20.000 nodi)
Queries (Test)	1000	Target di retrieval esatto

Allineamento Rigoroso Immagini-Grafi

Corrispondenza 1-a-1 tramite `image_id`. Nessuna discrepanza tra le gallerie di valutazione visive e a grafo.

Integrazione Semantica: Ontologia OWL & Virtuoso

Arricchimento ontologico gerarchico per superare il vocabolario piatto

1. Modellazione TBox con Protégé

Definita un'ontologia **OWL** per strutturare il vocabolario aperto di GQA:

- ▶ ~**300 classi base** di oggetti e attributi.
- ▶ Raggruppate in **20 Macro-Categorie** gerarchiche (es. Animale, Veicolo, Arredamento).
- ▶ Regole di transitività e disgiunzione semantica.

2. Triple Store Virtuoso & Reasoning

Interrogazione SPARQL automatizzata: il ragionatore inferisce automaticamente le super-classi dei nodi.

3. Feature Ingestion in Nomic (768-D)

La stringa testuale di ciascun nodo viene canonicamente arricchita:

`"classe + macro_categoria + attributi"`

- ▶ Generazione di vettori densi a **768 dimensioni** con nomic-embed-text-v1.5.
- ▶ **Effetto Chiave:** Nodi lessicalmente disgiunti (*cat* e *dog*) condividono la regione Animale prima ancora dell'ingresso nella GCN!

Le Baseline Visive: ResNet-50 e CLIP

Due termini di paragone scelti agli estremi dello spettro delle rappresentazioni



ResNet-50: la baseline attesa

- ▶ Pesi IMAGENET1K_V2, head di classificazione sostituita da un'identità.
- ▶ Uscita del global average pooling: **2048-D**.
- ▶ Addestrata a riconoscere *un* oggetto dominante per immagine.

CLIP: la baseline difficile

- ▶ Vision transformer e proiezione multimodale: **512-D**.
- ▶ Allineato al testo su ~ 400 milioni di coppie immagine-didascalia.
- ▶ Coglie concetti di scena che una rete di classificazione non esprime.


Entrambe **congelate**, senza fine-tuning, indicizzate con lo stesso FAISS e valutate con lo stesso protocollo dei modelli a grafo.

Ground Truth Semantica e Mining dei Positivi

Definizione deterministica di similarità, senza annotazione manuale

$$s(A, B) = \alpha J_w(\mathcal{O}_A, \mathcal{O}_B) + (1 - \alpha) J_w(\mathcal{T}_A, \mathcal{T}_B), \quad \alpha = 0,5$$

$\mathcal{O}$ insieme degli oggetti $\mathcal{T}$ triple d'azione (*src, rel, dst*) J_w Jaccard pesata con IDF



Validazione esterna con CLIP


CLIP osserva i pixel e non ha accesso ai grafi. Precisione visiva del mining **60 %**, contro il 5 % di una selezione casuale.

Soglia minima di informazione

Le ancore con meno di 3 oggetti sono scartate: precisione 30 % contro 54–62 % a partire dal terzo oggetto.

Architettura del Graph Encoder: GINE vs. GraphSAGE

Le due varianti differiscono solo nel trattamento dell'etichetta dell'arco



GINE (Rel): il predicato entra nel messaggio



L'embedding dell'arco viene sommato a quello del vicino prima della propagazione: *cavalca* e *accarezza* generano rappresentazioni distinte.

GraphSAGE (NoRel): sola topologia




Media delle feature dei vicini, etichetta ignorata. Impiega inoltre metà dei parametri, 0,79 M contro 1,64 M.

Apprendimento Contrastivo: Triplet Margin vs. NT-Xent

La selezione dei negativi determina la geometria dello spazio appreso

Triplet Margin con mining *semi-hard*



Ammessi i soli negativi con $D(a, p) < D(a, n) < D(a, p) + m$, con margine $m = 0,3$. Quelli distanti non producono gradiente, quelli interni sono spesso positivi non etichettati. **Robusto al rumore del mining automatico.**

NT-Xent: normalizzazione sull'intero batch

Softmax sui 256 negativi del batch, $\tau = 0,2$. Penalizza in modo uniforme le scene scorrelate e quelle parzialmente affini, frammentando lo spazio.

Protocollo di ottimizzazione

- ▶ AdamW, cosine annealing, 300 epoche.
- ▶ Coseno fuori-diagonale $< 0,10$: nessun collasso.
- ▶ ~ 11 minuti per run su L40S.

Risultati di Retrieval: Benchmark su Subset (15k) e Fullset (55k)

Le GNN superano nettamente le baseline puramente visive (CLIP e ResNet-50)

Confronto Metrico Principale (Accuracy@20 / HitRate)

Metodo	Configurazione	Acc@20 (15k)	Acc@20 (55k)
ResNet-50	Pixel (2048-D)	44,88%	37,00%
CLIP ViT-B/32	Vision-Lang (512-D)	44,36%	41,20%
GRAPHSAGE + NT-Xent	GQA Nativo	64,46%	58,10%
GINE + NT-Xent	GQA Nativo	67,06%	61,30%
GRAPHSAGE + Triplet	Semantic Web	79,90%	65,10%
GINE + Triplet	Semantic Web	81,58%	67,20%

Superiorità Costante ad Acc@20

- ▶ **Distacco su CLIP (Acc@20):**
+37,22% sul Subset (15k)
+26,00% sul Full-Set (55k).
- ▶ **Distacco su ResNet-50 (Acc@20):**
+36,70% sul Subset (15k)
+30,20% sul Full-Set (55k).
- ▶ **Flessione su 20k Distrattori:**
Calo controllato di $\sim 14\%$ preservando intatta la gerarchia dei modelli.

Ablation Study: Cosa Determina la Performance?

Isolamento dei contributi misurato uniformemente su Accuracy@20 (HitRate)

1. Scelta della Loss

+5,70% Acc@20

(su 55k, +3,24% su 15k)

[+8,95% a Top-1 Precision]

- ▶ **Architrave Metrico:** Il margine locale batte la softmax globale.
- ▶ Evita repulsioni su scene affini nel batch.

2. Convoluzione Edge-Aware

+2,10% Acc@20

(su 55k, +1,68% su 15k)

[+2,59% a Top-1 Precision]

- ▶ **Semantica degli Archi:** Disambigua le relazioni persona-oggetto (*cavalca* vs. *accarezza*).
- ▶ Vantaggio costante a parità di setup.

3. Arricchimento Ontologico

+13,23% Acc@20

(su 15k: 81,58% vs 68,35%)

[+7,26% a Top-1 Precision]

- ▶ **Regolarizzazione a-priori:** Le super-classi unificano sinonimi (*cat* e *dog* sotto *Animale*).
- ▶ Salto di HitRate decisivo.

Conclusione Metodologica: La combinazione ottimale richiede **tutti e tre i pilastri** operanti all'unisono.

Generalizzazione Zero-Shot: Trasferimento tra Domini

Analisi incrociata 55k $\leftrightarrow$ 15k e studio dello shift distributivo

1. Forward Cross-Eval (55k $\rightarrow$ 15k)

Modello Fullset valutato su Galleria 15k:

- ▶ Raggiunge il picco assoluto: **81,71% Acc@20** e **49,68% Top-1 Precision!**
- ▶ **Feature Mismatch Ontologico:** Il modello senza ontologia crolla a 63,55% ($-18,16\%$) a causa dello shift distributivo dei nodi.

2. Reverse Cross-Eval (15k $\rightarrow$ 55k)


Modello Subset valutato su Galleria 55k:

- ▶ L'Acc@20 cala bruscamente al **49,70%** ($-17,50\%$ vs 55k nativo a 67,20%).
- ▶ **Conferma Scientifica:** Un modello addestrato su sole 15k scene non ha visto abbastanza varietà relazionale per reggere 20.000 distrattori.
- ▶ Giustifica la necessità del training su larga scala HPC.

Robustezza Strutturale ed Explainability


Resilienza a occlusioni (Self-Retrieval) e trasparenza decisionale con GNNExplainer

Test di Robustezza (Dropout 0–40%)



- ▶ **Resilienza Non-Lineare:** Con il 20% di nodi rimossi, l'Acc@20 resta al **97,50%**.
- ▶ Al 40% di distruzione, l'Acc@20 regge all'**87,20%** (P@1 a 64,80%).
- ▶ Il pooling distribuisce il contesto globale.

Explainability con GNNExplainer



- ▶ Ottimizzazione regressione latente su scena 2363112.
- ▶ **Nodi Salienti ($> 0,085$):** *Hair, Arm, Ocean*.
- ▶ Nodi di sfondo ricevono peso trascurabile.

Analisi Qualitativa: Risultati Reali e Failure Case

Visualizzazione concreta del retrieval tramite GCN GINE e casi limite

1. Caso di Successo: Struttura Relazionale Preservata (Top-5 Retrieval)

Query



Top-5 Risultati Recuperati (FAISS IndexFlatIP)



2. Failure Case: Rumore di Sfondo Dominante nel Mean Pooling

Query



Top-5 Risultati (Saturazione da Nodi Generici / Sfondo)



Estensioni di Sistema: Dynamic VLM & Deployment

Dall'immagine grezza dell'utente al retrieval distribuito in tempo reale

Dynamic Scene Graph Extractor (VLM)


Qwen2.5-VL-7B su cluster HPC per estrarre grafi da immagini arbitrarie caricate dall'utente:

- ▶ **Constrained JSON Prompting:** forzatura sintattica.
- ▶ **Mappatura Ontologica Virtuoso:** aggancio deterministico delle macro-categorie per evitare allucinazioni aperte.

Architettura Locale (K3s & Docker)

Gateway FastAPI asincrono → Coda RabbitMQ → AI Worker
→ Caching Redis → PostgreSQL.

Infrastruttura Cloud IaC (Terraform su AWS)



- ▶ VPC multi-AZ con ALB e nodi Kubernetes EC2.
- ▶ Servizi gestiti enterprise: Amazon S3, SQS, RDS, ElastiCache.

Conclusioni, Limiti e Prospettive Future

Sintesi dei contributi scientifici e lezioni apprese

Messaggio Principale

L'integrazione di Scene Graph, ontologie OWL e Graph Neural Networks edge-aware supera nettamente i modelli puramente visivi (CLIP e ResNet) nel retrieval composizionale, garantendo interpretabilità e scalabilità.

3 Takeaway Concreti

1. **Struttura > Pixel:** Le relazioni esplicite battono i modelli multimodali fondazionali (+26% su CLIP).
2. **Ontologie come Regularizzatori:** Le super-classi appiattiscono la varianza lessicale.
3. **Triplet Margin Indispensabile:** Tolleranza geometrica fondamentale su dati complessi.

Limiti e Sviluppi Futuri

- ▶ **Limiti:** Allucinazioni VLM su scene ultra-affollate; saturazione da nodi generici di sfondo.
- ▶ **Sviluppi Futuri:**
 - ▶ Filtri di salienza semantica a monte dell'encoder.
 - ▶ Meccanismi di Edge Attention e Pooling Gerarchico.
 - ▶ Valutazione end-to-end su benchmark standardizzati.

Grazie per l'attenzione!

Spazio per Domande e Risposte (Q&A)

Repository GitHub: <https://github.com/saintslisi/deeplearning2>

Gruppo DL26: Santi Lisi Dario Lazzara Francesco Granata

Backup 1: Iperparametri Completi & Dettagli di Training

Specifiche di riproducibilità sul cluster HPC UNICT

Iperparametri

Parametro	Valore
Dimensione Input Nodo	768 (Nomic Embeddings)
Dimensione Nascosta	256
Dimensione Output	256 (Normalizzato ℓ_2)
Layer Convolutivi	3 (BatchNorm + ReLU + Dropout 0.3)
Pooling	Global Mean Pooling
Projection Head	MLP 256 $\rightarrow$ 256 $\rightarrow$ 256
Ottimizzatore	AdamW ($\text{lr} = 10^{-3}$, decay 10^{-4})
Scheduler	Cosine Annealing (300 epoche)
Batch Size	128 elementi

Specifiche Hardware Cluster HPC

- ▶ **GPU:** NVIDIA L40S (Ada Lovelace).
- ▶ **Container:** Apptainer (Python 3.11, PyTorch 2.7, PyG 2.8).
- ▶ **Tempo di Training per modello:** $\sim 10'44''$ per GINE e $\sim 10'29''$ per SAGE.
- ▶ **Overhead relazionale:** Solo +2–7% di costo computazionale.

Backup 2: Formulazione Matematica Ground Truth

Equazioni esatte di Jaccard pesata, Veto ed Embedding Centrato

Indice di Jaccard Pesato

$$J_w(\mathcal{A}, \mathcal{B}) = \frac{\sum_{x \in \mathcal{A} \cap \mathcal{B}} \text{IDF}(x) \cdot w_{\text{att}}(x)}{\sum_{y \in \mathcal{A} \cup \mathcal{B}} \text{IDF}(y) \cdot w_{\text{att}}(y)}$$

Embedding Semantico IDF-Centrato

$$\mathbf{e}_s = \frac{\sum_{v \in V} \text{IDF}(v) \mathbf{x}_v}{\sum_{v \in V} \text{IDF}(v)} - \boldsymbol{\mu}_{\text{corpus}}$$

$$\cos_{\text{sem}} = \frac{\mathbf{e}_A \cdot \mathbf{e}_B}{\|\mathbf{e}_A\|_2 \|\mathbf{e}_B\|_2}$$

Regole Decisionali di Accettazione

- ▶ **Bypass Diretto:** Se $s(A, B) \geq 0,30 \implies$ **Accettato.**
- ▶ **Veto Condizionato:** Se $0,15 \leq s(A, B) < 0,30 \wedge \cos_{\text{sem}} \geq 0,55 \implies$ **Accettato.**
- ▶ **Scarto:** Altrimenti $\implies$ **Respinto.**

Backup 3: Formulazione di Encoder e Loss

Equazioni rimosse dal corpo per leggibilità

Message Passing GINE

$$\mathbf{h}_v^{(l)} = \text{MLP}\left((1 + \epsilon) \mathbf{h}_v^{(l-1)} + \sum_{u \in \mathcal{N}(v)} \text{ReLU}(\mathbf{h}_u^{(l-1)} + \mathbf{e}_{uv})\right)$$

- ▶ $\mathbf{e}_{uv}$: embedding 768-D del predicato.
- ▶ Aggregazione per somma; GRAPH-SAGE usa la media e una sola trasformazione lineare per lato.
- ▶ Parametri: 1,64 M contro 0,79 M.

Triplet Margin e NT-Xent

$$\mathcal{L}_{\text{triplet}} = \max\left(0, D(\mathbf{z}_a, \mathbf{z}_p) - D(\mathbf{z}_a, \mathbf{z}_n) + m\right), \quad m = 0,3$$

$$\mathcal{L}_{\text{NT-Xent}} = -\log \frac{\exp(\text{sim}(\mathbf{z}_a, \mathbf{z}_p)/\tau)}{\sum_{k \neq a} \exp(\text{sim}(\mathbf{z}_a, \mathbf{z}_k)/\tau)}, \quad \tau = 0,2$$

- ▶ D : distanza coseno su embedding ℓ_2 -normalizzati.
- ▶ Semi-hard: $D(a, p) < D(a, n) < D(a, p) + m$.